Coding Dojo

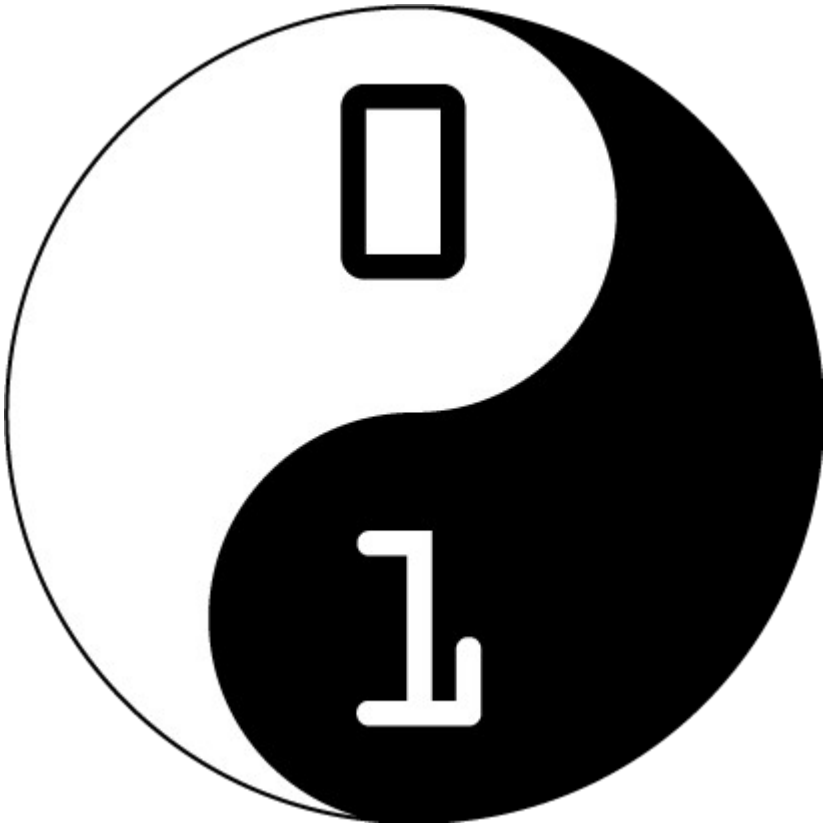

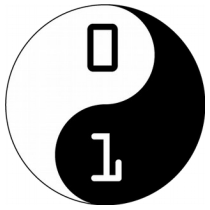

Coding Dojo - Regras

- Ponto de participação, poderá perdido se:
  - Indisciplina
  - Aluno atrasado (ver política de atraso na especificação)
  - Recusar participação como piloto/copiloto
    - Ou não querer sair do computador, quando solicitado :-)
    - Demorar para sair quando solicitado
  - Parar de participar por:
    - Uso de outro computador
    - Uso de celular
    - Usar a internet
    - Conversa

Coding Dojo

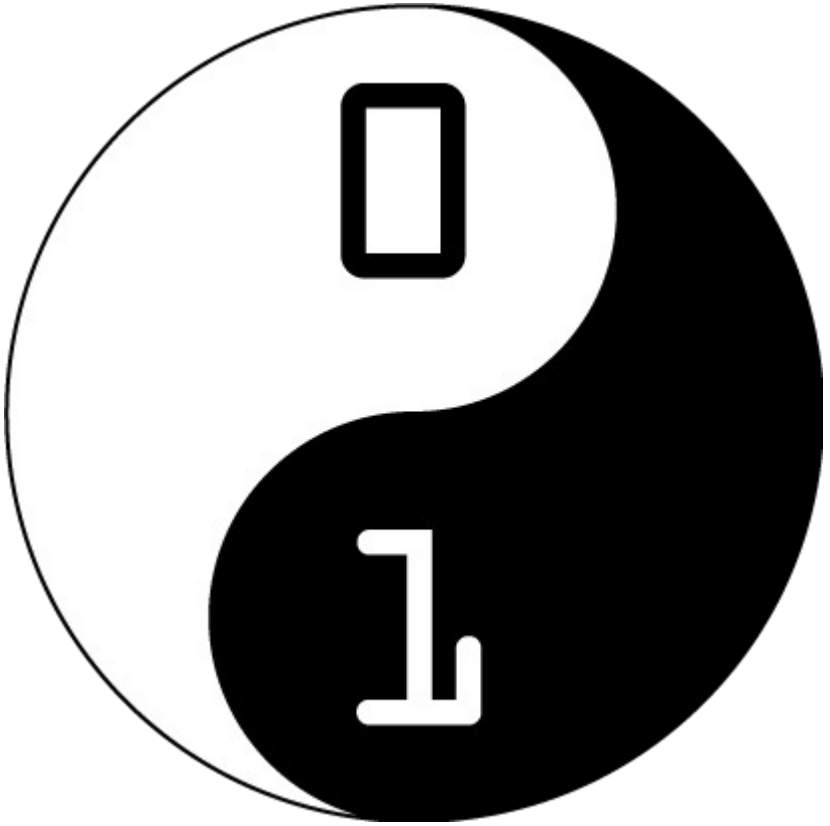

Escalonador Simples

Coding Dojo - Escalonador

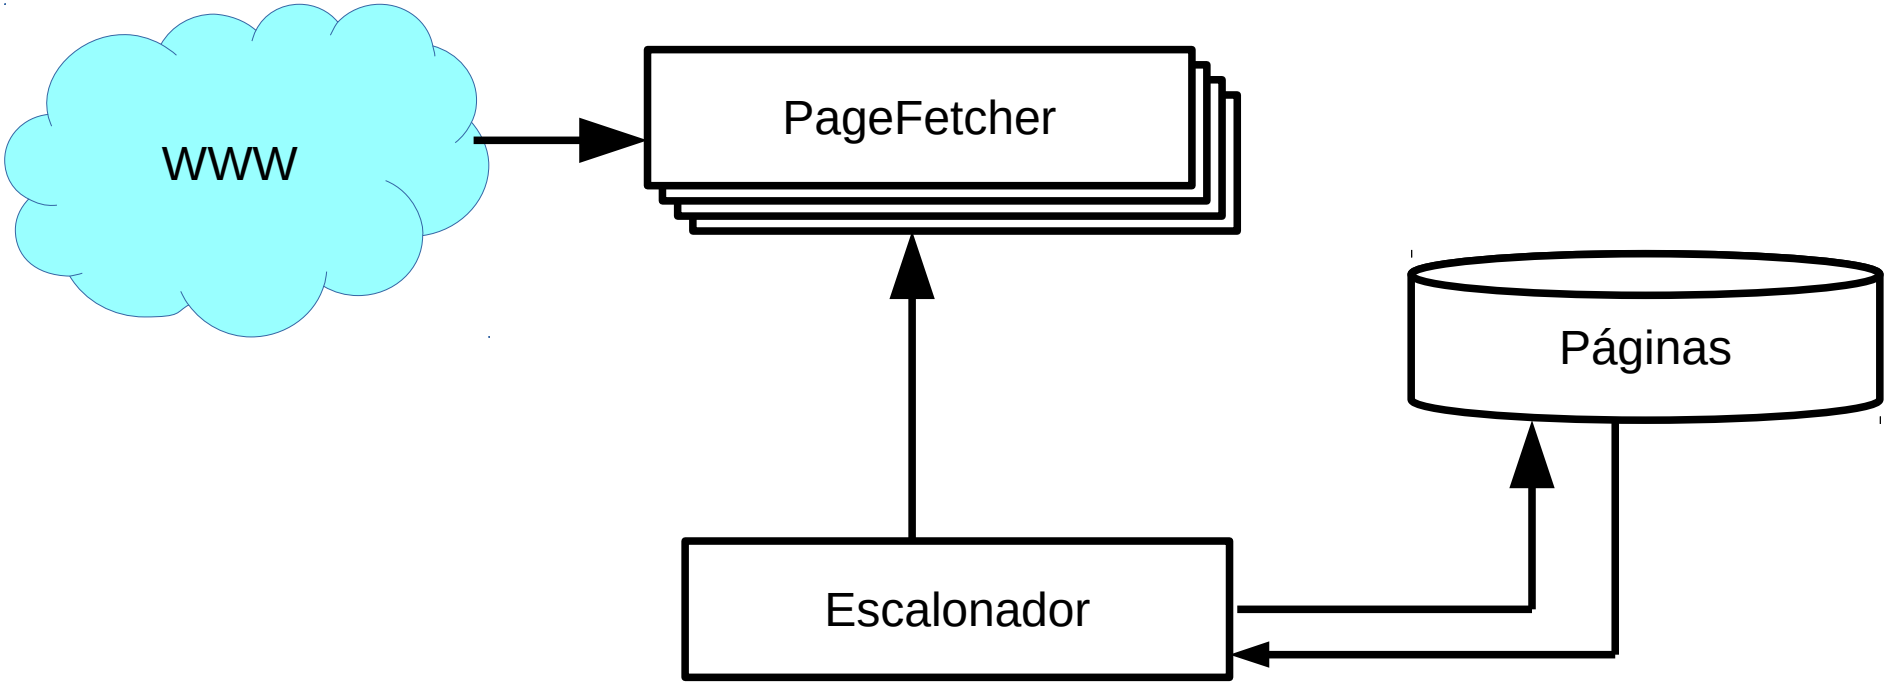

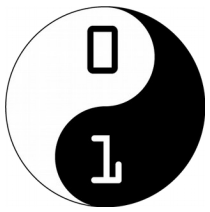

Coding Dojo – Escalonador Estrutura Geral

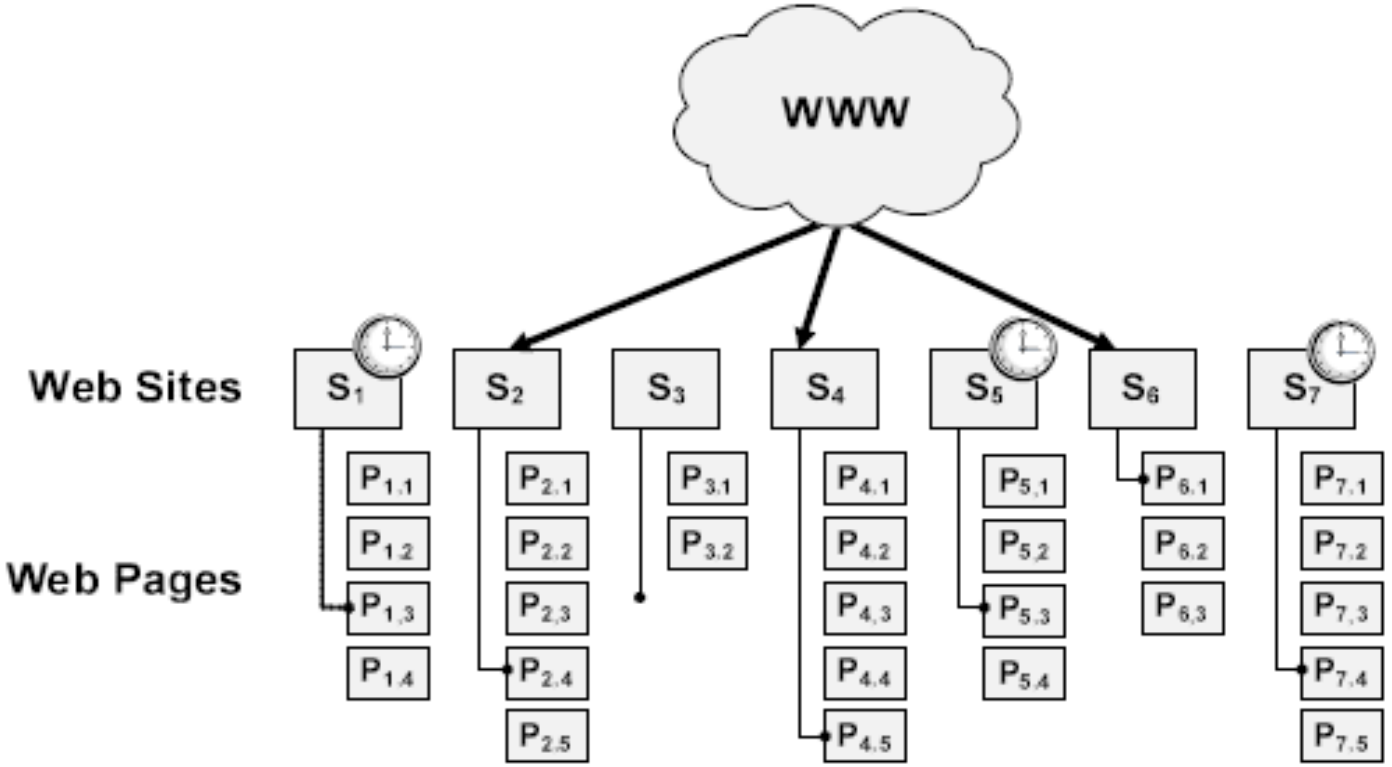

- Devemos, inicialmente:
  - Usar a classe servidor para armazenar:
    - O nome do servidor
      - Para simplificar, usaremos o hostname.
    - O horário do último acesso

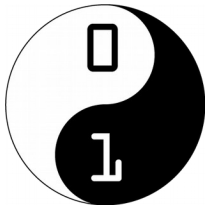

Coding Dojo – Escalonador
Classe Servidor

- Modifique a classe servidor para que:
  - no método **acessadoAgora** o atributo lastAccess com o horário atual.
  - o método **getTimeSinceLastAcess** retorne quanto tempo (em milisegundos) se passou desde o último acesso ao servidor
  - o método **isAccessible** retorne **true** caso o tempo que se passou desde o último acesso seja maior que a constante **ACESSO_MILIS** e retornará **false**, caso contrário
- Use o método System.currentTimeMillis() para saber o horário atual

Coding Dojo – Escalonador
Classe EscalonadorSimples

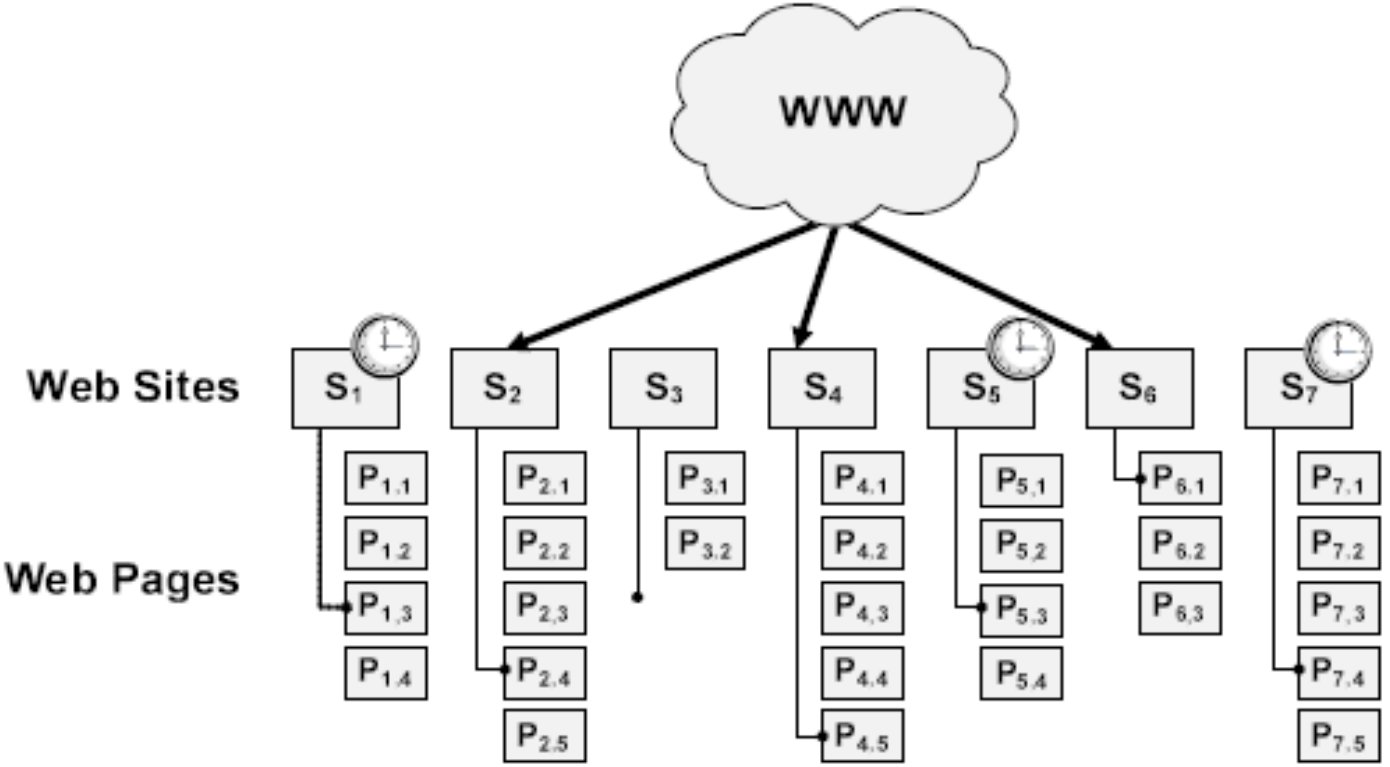

- Cada servidor possuir uma fila de páginas.
  - Crie um Map (LinkedHashMap) em que a chave é o servidor e, o valor, é uma fila de páginas
    - O LinkedHashMap preserva a ordem de inserção
- Deverá existir uma fila de servidores

- As filas podem ser implementadas como ArrayList ou LinkedList

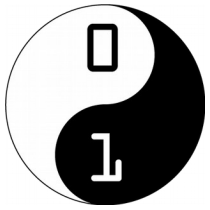

Coding Dojo – Escalonador
Método: adicionaNovaPagina

Este método adiciona uma nova URL na fila, retornando **true**, caso tenha adicionado com sucesso.

- Este método retorna **false** caso não seja possível adicionar esta página, ou seja:
  - Se página já foi adicionada (alguma hora) na fila
    - Precisamos de mais alguma estrutura para isso!
  - Se profundidade esteja maior que o previsto
    - A classe **URLAddress** possui o atributo **depth** para isso
    - Crie uma constance na classe EscalonadorSimples para indicar o limite de profundidade
- Ao adicionar a URL na fila:
  - Caso este servidor não exista, o mesmo deve ser criado para antes de adicionar a esta URL
    - Use os metodos do Map: containsKey(key), put(key,val) e get(key)

- Você irá precisar de utilizar o método getAddress() da URL pois ele retorna o endereço URL (sem parâmetros):

http://www.google.com/?q=asdkasodk

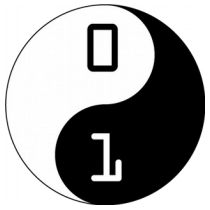

Coding Dojo – Escalonador
Método: getURL

Este método retorna a próxima URL na fila, removendo-a da mesma.

Caso não encontre URL, pode ser por dois motivos:

- Caso exista URL mas o servidor não está acessível no momento: o método getURL espera 1 segundo e procura por servidores disponíveis novamente.
- Caso a fila esteja vazia: retorne null

Assim, o método getURL será da seguinte forma:

- Procure o primeiro servidor acessível. Caso encontre:
  - Extraia o primeiro elemento da fila (removendo-o).
  - Invoque o método **acessadoAgora** deste servidor para indicar que ele foi acessado
  - Caso a fila deste servidor esteja vazia, elimine esse servidor da fila
  - Retorne esta URL

- Caso não encontre URL, ponha a thread para esperar 1 segundo e, logo após, procure novamente.

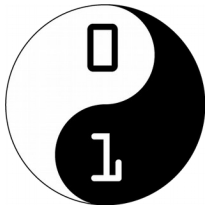

Coding Dojo – Escalonador Gerenciamento do Robots.txt

Exemplo de uso da API JRobotX:

```
RobotExclusion robotExclusion = new RobotExclusion();

Record rFB = robotExclusion.get(new URL("https://www.facebook.com/robots.txt"),"daniBot");
System.out.println("Aceitou o fb index?  "+rFB.allows("/index.html"));
System.out.println("Aceitou o fb o cgi-bin?  "+rFB.allows("/cgi-bin/oioi"));
System.out.println("Aceitou o fb o oioi?  "+rFB.allows("/lala/oioi"));

Record rTerra = robotExclusion.get(new URL("http://www.terra.com.br/robots.txt"),"daniBot");
System.out.println("Aceitou o terra index?  "+rTerra.allows("/index.html"));
System.out.println("Aceitou o terra o cgi-bin?  "+rTerra.allows("/cgi-bin/oioi"));
System.out.println("Aceitou o terra o oioi?  "+rTerra.allows("/lala/oioi"));
```

O método **get** (sublinhado) fará a requisição ao robots.txt e retornará uma instancia do tipo Record.

Como a Requisição tem um custo alto, quem deve fazê-la é o **PageFetcher**.

Mas, as instancias de Record por servidor devem ser armazenadas de forma centralizada - no **Escalonador (**classe **EscalonadorSimples**, no caso)

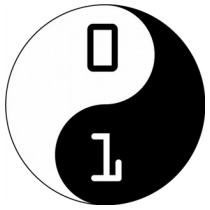

Coding Dojo – Escalonador Gerenciamento do Robots.txt

No **EscalonadorSimples**, você deverá criar:

- Um atributo do HashMap para mapear cada servidor (chave) ao seu respectivo Record (valor)

- O método getRecordAllowRobots que retorna o Record de um determinado domínio de uma URL (passada como parâmetro)
  - Retorna null caso não exista

- O método putRecorded (threadsafe) que adiciona uma instância Record referente a um determinado domínio

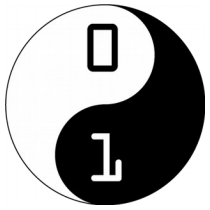

Coding Dojo – Escalonador

Contabilizar páginas e Finalizar coleta

A coleta será finalizada após serem coletadas 1.000 páginas (inicialmente, você pode diminuir o número máximo, para testar). Para que isso seja possível crie:

- um atibuto na classe EscalonadorSimples que será o contador de páginas coletadas

- o método **CountFetchedPage** que incrementa o contador de páginas coletadas. O PageFetcher que deverá executar este método sempre que colete com sucesso uma página

- o método **finalizouColeta** que retorna verdadeiro caso já tenha coletado o limite de páginas a coletar.
  - crie a constante que indica o limite de páginas a coletar

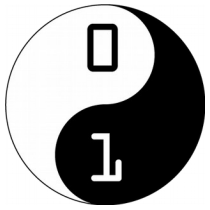

Coding Dojo – Escalonador

Quais métodos precisam **ThreadSafe**?

Na classe EscalonadorSimples existem métodos que não são ThreadSafe e deveriam ser.

Faça com que esses métodos sejam ThreadSafe

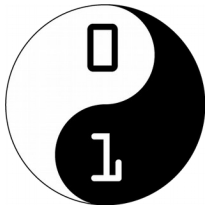

Coding Dojo – PageFetcher

Crie a classe PageFetcher que será uma Thread. Para isso leve em consideração:

- A classe PageFetcher será uma Thread. Em nosso coletor, haverá diversas instancias de PageFetcher e um único Escalonador que todos os PageFetchers irão usar. Dessa forma, o Escalonador será o “objeto compartilhado” das threads, pois ele compartilha a lista de URLs. Veja os slides sobre threads para se basear e contruir o PageFetcher.

- Para fazer o método run (mais detalhes no próximo slide), lembre-se que a Thread deverá só ser finalizada quando finalizar a coleta. O Escalonador possui um método para verificar isso.

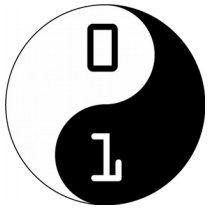

Coding Dojo – PageFetcher método run

- O PageFetcher irá requisitar uma nova URL ao Escalonador (sem baixá-la) para:

  - Após receber a URL do escalonador, solicitar o Record do domínio desta URL (este objeto solicitado é o robots.txt do dominio):
  - Caso ainda não exista esse Record, faça a requisição usando a API jrobotx para obter esse Record. Logo após, invoque o metodo do escalonador que adiciona para esse determinado domínio a instancia Record criada.

  - Logo após a obtenção do Record, verificar se essa url pode ser coletada. Caso seja possível:
  - Baixe página referente à esta URL
  - Extraia seus links (podendo utilizar uma API para isso)
  - Adicionar os links no escalonador. Transformando possíveis UR relativas em absolutas, há um método no ColetorUtil para identificar URL relativa.